



Evaluación 5 – Análisis de Clústeres

Fecha de Entrega: domingo 25 de julio

El objetivo de esta evaluación es utilizar el algoritmo K Means para obtener clústeres. La base de datos contiene registros de 1.000 de evaluación de riesgo crediticio de un banco alemán (los mismos datos utilizados en la Evaluación 4). La descripción de las variables de la base de datos se encuentra en la siguiente página.

La evaluación consta de dos etapas:

1. Seleccionar el valor de K y las variables explicativas para aplicar el algoritmo (justificando adecuadamente la selección).
2. Analizar y describir los resultados del algoritmo, utilizando el K seleccionado. Algunas posibles preguntas a considerar en esta etapa son:
 - a. ¿Cuántas observaciones posee cada clúster?
 - b. ¿Es posible “ponerle nombre” a cada clúster?
 - c. ¿Cómo es la cohesión/separación de los clústeres resultantes?

Debe generar un breve reporte con su análisis y entregarlo hasta el domingo 25 de julio al correo: mineria.datos.PUC@gmail.com. El asunto del correo y el nombre del archivo deben comenzar con [Evaluación 5] seguido con los apellidos de los estudiantes. Ejemplo: “[Evaluación 5] Gutiérrez y Soto”.

El objetivo de la tarea es demostrar que entiende lo que está haciendo R al aplicar K Means. Por favor presente sólo la información relevante, sin llenar múltiples páginas con gráficos, códigos y estadísticas.



Descripción de la Base de Datos

Nombre	Descripción	Tipo	Valores
status	Historial de cuenta corriente	Categórica	1 = sin cuenta 2 = cuenta con deuda 3 = ahorros hasta 200 DM 4 = ahorros desde 200 DM
history	Historial de créditos	Categórica	0 = retrasos en el pasado 1 = cuenta crítica o créditos en otros bancos 2 = sin créditos anteriores 3 = créditos vigentes al día 4 = todos los créditos pagados
amount	Monto del crédito (transformado por confidencialidad)	Continua	-
savings	Historial de ahorros	Ordinal	1 = Sin ahorros 2 = Menos de 100 DM 3 = Entre 100 y 500 DM 4 = Entre 500 y 1.000 DM 5 = Más de 1.000 DM
employed	Tiempo empleado	Ordinal	1 = Desempleado 2 = Menos de 1 año 3 = Entre 1 y 4 años 4 = Entre 4 y 7 años 5 = Más de 7 años
rate	Tasa del crédito en proporción del ingreso	Ordinal	1 = Más de 35% 2 = Entre 25% y 35% 3 = Entre 20% y 25% 4 = Menos de 20%
personal	Estado civil y sexo	Categórica	1 = Hombre divorciado 2 = Hombre soltero * 2 = Mujer no soltera * 3 = Hombre casado o viudo 4 = Mujer soltera
residence	Tiempo en la residencia	Ordinal	1 = Menos de 1 año 2 = Entre 1 y 4 años 3 = Entre 4 y 7 años 4 = Más de 7 años
property	Bien más valioso	Ordinal	1 = Nada 2 = Auto 3 = Seguro de vida 4 = Propiedad



age	Edad	Continua	-
housing	Tipo de vivienda	Categórica	1 = Gratuita 2 = Arrendada 3 = Propia
credits	Créditos vigentes	Ordinal	1 = 1 2 = 2 o 3 3 = 4 o 5 4 = 6 o más
job	Nivel de empleabilidad	Ordinal	1 = desempleado 2 = no calificado 3 = calificado dependiente 4 = gerente / independiente
persons	Carga familiar	Binaria	0 = 2 o menos , 1 = 3 o más
telephone	Tiene teléfono fijo	Binaria	0 = no , 1 = sí
foreign	Extranjero	Binaria	0 = no , 1 = sí
credit	Evaluación de riesgo	Binaria	0 = mala , 1 = buena

Su entrega será evaluada de acuerdo con los siguientes aspectos:

Claridad [1,5 puntos]

Se espera que el reporte sea claro y bien redactado, con las ideas debidamente desarrolladas. Las tablas y figuras deben estar debidamente presentadas y explicadas. El procedimiento de aplicación del algoritmo se explica adecuadamente. El lenguaje utilizado debe ser apropiado para un reporte técnico.

Modelación [3 puntos]

El algoritmo se debe aplicar correctamente. Se debe explicitar y justificar la selección del parámetro K. Se deben explicitar y justificar las variables utilizadas en el modelo.

Análisis de Resultados [1,5 puntos]

Se analizan y describen los resultados más relevantes del algoritmo. Se analiza la composición de cada clúster. Se analiza la calidad de los resultados. Se aplican de manera adecuada los distintos contenidos y criterios vistos en clases.